

VINOTINTO GALÁCTICO NEWS EXTRACTOR

Documento Maestro de Especificación Funcional y Técnica

Versión

1.0

Estado

Definido y aprobado

1. OBJETIVO DEL PROYECTO

Crear un extractor de noticias deportivas orientado a la producción de contenido para YouTube.

El objetivo NO es crear un agregador de noticias genérico.

El objetivo NO es crear un buscador de noticias.

El objetivo NO es crear un crawler web.

El objetivo es ahorrar tiempo de lectura manual y generar un archivo consolidado con noticias deportivas relevantes para posteriormente ser procesadas por un prompt que generará guiones para videos.

2. FILOSOFÍA DEL PROYECTO

El sistema debe ser extremadamente obediente.

No debe intentar ser inteligente.

No debe descubrir contenido.

No debe buscar fuentes nuevas.

No debe navegar libremente.

El usuario ya realizó manualmente la selección y validación de las fuentes.

Por lo tanto:

EL EXCEL ES LA ÚNICA FUENTE DE VERDAD.

3. REGLA ABSOLUTA

El sistema solamente puede entrar a URLs definidas por el usuario.

Está prohibido:

- Explorar dominios.
- Buscar categorías.
- Buscar noticias relacionadas.
- Seguir enlaces sugeridos.
- Descubrir nuevas rutas.
- Reemplazar URLs.

Cada checkbox de la interfaz estará asociado a una URL exacta del Excel.

La URL utilizada debe coincidir exactamente con la URL proporcionada por el usuario.

4. TEMÁTICAS A CUBRIR

Real Madrid Masculino

Primer equipo exclusivamente.

No Castilla.

No Juveniles.

No cantera.

Real Madrid Femenino

Primer equipo exclusivamente.

LaLiga

Equipos de Primera División únicamente.

No Segunda División.

No categorías inferiores.

Selección Española Masculina

Primer equipo exclusivamente.

Selección Española Femenina

Primer equipo exclusivamente.

Vinotinto Masculina

Selección absoluta exclusivamente.

Vinotinto Femenina

Selección absoluta exclusivamente.

Liga FUTVE

Primeras divisiones profesionales únicamente.

5. ORIGEN DE LOS DATOS

Archivo Excel:

Prensa Deportiva.xlsx

El Excel contiene:

- Categorías.
- URLs verificadas.
- Secciones específicas seleccionadas manualmente por el usuario.

El programa debe leer directamente este archivo.

No se utilizarán configuraciones duplicadas.

No se utilizarán JSON paralelos.

No se utilizarán listas manuales de URLs fuera del Excel.

6. INTERFAZ

Tecnología:

Streamlit

Interfaz web local.

Ejecución:

```
streamlit run app.py
```

Acceso:

<http://localhost:8501>

7. PRESENTACIÓN DE FUENTES

La interfaz mostrará nombres amigables.

Ejemplo:

REAL MADRID

- Real Madrid Oficial
- AS - Real Madrid
- Marca - Real Madrid
- Mundo Deportivo - Real Madrid
- Defensa Central
- Madridista Real
- Sport - Real Madrid

Aunque visualmente se muestren nombres amigables, internamente siempre se utilizará la URL exacta del Excel.

8. FLUJO DE EXTRACCIÓN

Para cada fuente seleccionada:

1. Abrir la URL exacta.
2. Detectar titulares visibles.
3. Tomar máximo tres noticias.
4. Abrir cada noticia.
5. Validar fecha.
6. Extraer contenido.

- 7. Limpiar contenido.
 - 8. Guardar resultados.
-

9. REGLA DE FECHAS

Solo se extraerán noticias del día actual.

Ejemplos:

Si hoy es 7 de junio:

- Noticias del 7 de junio: válidas.
- Noticias anteriores: ignoradas.

Si una fuente tiene:

- 3 noticias del día → extraer 3.
- 2 noticias del día → extraer 2.
- 1 noticia del día → extraer 1.
- 0 noticias del día → generar reporte indicando ausencia de noticias.

Nunca se rellenarán huecos con noticias antiguas.

10. DATOS A EXTRAER

Por cada noticia:

- Título.
 - Subtítulo (si existe).
 - Autor.
 - Fecha.
 - URL.
 - Cuerpo completo limpio.
-

11. DATOS A ELIMINAR

Eliminar:

- Publicidad.
- Redes sociales.
- Noticias relacionadas.
- Recomendaciones.
- Newsletter.
- Comentarios.
- Contenido patrocinado.

- Widgets externos.
- Elementos de navegación.

Mantener únicamente el contenido periodístico.

12. DUPLICADOS

No eliminar duplicados.

Si Marca y AS publican la misma noticia:

- Se guardan ambas.

La consolidación posterior será responsabilidad del prompt generador de guiones.

13. ARCHIVOS DE SALIDA

TXT

Archivo único:

noticias.txt

Contendrá todas las noticias extraídas.

HTML

Archivo:

noticias.html

Se utilizará para auditoría y comparación visual contra la fuente original.

14. INFORME DE CONTROL

El sistema generará un registro indicando:

- Fuente procesada.
- Número de noticias encontradas.
- Número de noticias extraídas.
- Errores detectados.
- Fuentes sin noticias del día.

Ejemplo:

Fuente: Marca Real Madrid

Noticias del día encontradas: 2

Extraídas: 2

Estado: Correcto

15. TECNOLOGÍA

Backend:

Python

Librerías:

- Playwright
 - BeautifulSoup4
 - Pandas
 - OpenPyXL
 - Streamlit
-

16. ARQUITECTURA

VG_Extractor/

app.py

data/ Prensa Deportiva.xlsx

core/ excel_reader.py article_parser.py date_validator.py html_exporter.py txt_exporter.py

extractores/.realmadrid.py as.py marca.py mundodeportivo.py meridiano.py generic.py

output/ noticias.txt noticias.html

logs/

17. OBJETIVO FINAL

Reducir al mínimo el tiempo necesario para recopilar noticias deportivas.

Flujo final:

Excel → Selección de fuentes → Extracción automática → TXT único → Prompt de generación de guiones → Vídeo de YouTube